

Aprendizaje Automático

Especialización en Analítica de Big Data

Facultad de Ingeniería

Clase 5.1 – Métricas de evaluación



Profesor: Felipe Palta
felpalta@uao.edu.co




CLASE 5.1 – MÉTRICAS DE EVALUACIÓN

- Diseño de experimentos de entrenamiento y prueba: Conjuntos de entrenamiento y prueba.
- Training y Testing dataset.
- Matriz de Confusión.
- Indicadores clave en la Matriz de Confusión.
- Ejemplo Iris Dataset



DISEÑO DE EXPERIMENTOS DE ENTRENAMIENTO Y PRUEBA



Conjunto de datos de entrenamiento: Usado para entrenar un modelo de aprendizaje automático.

Conjunto de datos de prueba: Usado para evaluar el rendimiento del modelo en datos no vistos durante el entrenamiento.


TRAINING DATASET

Training dataset

Ajustar/entrenar el modelo de aprendizaje de máquina.


Es el responsable de la precisión (**accuracy**) y la capacidad de predicción del modelo.

División del
conjunto de datos




Aunque el valor puede ser variable, el Training dataset puede ser mayor o igual al 60% del total de datos del proyecto.

TESTING DATASET




Aunque el valor puede ser variable, el Test dataset puede ser entre el 20-25% del dataset original.

Debe de contener datos para cada tipo de escenario (clase) del problema determinado que se enfrentaría el modelo cuando se use en el mundo real.




MATRIZ DE CONFUSIÓN



- La variable objetivo (**target variable**) tiene dos valores: Positive o Negative.
- Las columnas representan el valor actual de la variable objetivo (**La verdad conocida**).
- Las filas corresponden a los **valores de predicción** del modelo de aprendizaje automático.


MATRIZ DE CONFUSIÓN – (TP)



TRUE POSITIVE (Verdaderos Positivos):

- El valor predicho por el modelo iguala (matches) con el valor actual.
- El valor actual era positivo y el modelo de aprendizaje automático lo predice como un valor positivo.


MATRIZ DE CONFUSIÓN – (TN)



TRUE NEGATIVE (Verdaderos Negativos):

- El valor predicho por el modelo iguala (matches) con el valor actual.
- El valor actual era negativo y el modelo de aprendizaje automático lo predice como un valor negativo.


MATRIZ DE CONFUSIÓN – (FP)



FALSE POSITIVE (Falsos Positivos):

- El valor predicho por el modelo no iguala al valor actual (**realiza una predicción falsa/errada**).
- El valor actual era negativo y el modelo de aprendizaje automático lo predice como un valor positivo.
- Los Falsos Positivos son conocidos como error Tipo 1 (**Type 1 error**).

MATRIZ DE CONFUSIÓN – (FN)



FALSE NEGATIVE (Falsos Negativos):

- El valor predicho por el modelo no iguala al valor actual (**realiza una predicción falsa/errada**).
- El valor actual era positivo y el modelo de aprendizaje automático lo predice como un valor negativo.
- Los Falsos Negativos son conocidos como error Tipo 2 (**Type 2 error**).

EJEMPLO MATRIZ DE CONFUSIÓN

Valores de la predicción	Tiene dolor de cabeza	100 True Positive (Verdaderos Positivos)	20 False Positive (Falsos Positivos)
	No tiene dolor de cabeza	30 False Negative (Falsos Negativos)	150 True Negative (Verdaderos Negativos)
		Tiene dolor de cabeza	No tiene dolor de cabeza
		Valores actuales	

- 100 **verdaderos positivos**, que fueron clasificados correctamente que tienen dolor de cabeza cuando si tienen dolor de cabeza.
- 150 **verdaderos negativos**, que fueron clasificados correctamente que no tienen dolor de cabeza cuando no tienen dolor de cabeza.
- 30 **falsos negativos**, que fueron clasificados como “no tienen dolor de cabeza” cuando en realidad “tiene dolor de cabeza”.
- 20 **falsos positivos**, que fueron clasificados como “tiene dolor de cabeza” cuando en realidad “no tienen dolor de cabeza”.

INDICADORES CLAVE EN LA MATRIZ DE CONFUSIÓN (ACCURACY)

Valores de la predicción	Tiene dolor de cabeza	100 True Positive (Verdaderos Positivos)	20 False Positive (Falsos Positivos)
	No tiene dolor de cabeza	30 False Negative (Falsos Negativos)	150 True Negative (Verdaderos Negativos)
		Tiene dolor de cabeza	No tiene dolor de cabeza
		Valores actuales	

$$\text{Classification Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$

La **Exactitud (accuracy)** define la frecuencia con la que el modelo predice el **resultado correcto**. Cuanto mayor sea la exactitud, mejor será el modelo.

$$\text{Accuracy} = \frac{100 + 150}{100 + 20 + 30 + 150} = 0.83 = 83\%$$

Significa que el modelo de aprendizaje de máquina tiene un 83% de **exactitud** en las predicciones.

INDICADORES CLAVE EN LA MATRIZ DE CONFUSIÓN (MISCLASSIFICATION RATE)

Valores de la predicción	Tiene dolor de cabeza	100 True Positive (Verdaderos Positivos)	20 False Positive (Falsos Positivos)
	No tiene dolor de cabeza	30 False Negative (Falsos Negativos)	150 True Negative (Verdaderos Negativos)
		Tiene dolor de cabeza	No tiene dolor de cabeza
		Valores actuales	

$$\text{Error rate} = \frac{FP + FN}{TP + FP + FN + TN}$$

La **tasa de clasificación errónea (error rate)** define la frecuencia con la que el modelo hace predicciones incorrectas.

$$\text{Error rate} = \frac{20 + 30}{100 + 20 + 30 + 150} = 0.17 = 17\%$$

Significa que el modelo de aprendizaje de máquina tiene un 17% de **imprecisión** en sus predicciones.

INDICADORES CLAVE EN LA MATRIZ DE CONFUSIÓN (PRECISION)

Valores de la predicción	Tiene dolor de cabeza	100 True Positive (Verdaderos Positivos)	20 False Positive (Falsos Positivos)
	No tiene dolor de cabeza	30 False Negative (Falsos Negativos)	150 True Negative (Verdaderos Negativos)
		Tiene dolor de cabeza	No tiene dolor de cabeza
		Valores actuales	

$$Precision = \frac{TP}{TP + FP}$$

La Precisión (Precision) compara el número de resultados correctos proporcionados por el modelo (Verdaderos positivos) con el número total de muestras positivas clasificadas (verdaderos positivos y falsos positivos). Es un indicador del desempeño del modelo y ayuda a medir la capacidad para clasificar muestras positivas.

$$Precision = \frac{100}{100 + 20} = 0.83 = 83\%$$

Esto significa que de todas las predicciones positivas, el 83% fueron ciertas.

INDICADORES CLAVE EN LA MATRIZ DE CONFUSIÓN (RECALL / SENSITIVITY)

True Positive Rate

$$Recall = \frac{TP}{TP + FN}$$

La Sensibilidad (recall / sensitivity) indica la capacidad del modelo para discriminar un caso positivo de uno negativo.

Representa la fracción de verdaderos positivos.

$$Recall = \frac{100}{100 + 30} = 0.76 = 76\%$$

Esto significa que de todos los casos positivos reales, solo el 76% ser predijeron correctamente.

Valores de la predicción	Tiene dolor de cabeza	100 True Positive (Verdaderos Positivos)	20 False Positive (Falsos Positivos)
	No tiene dolor de cabeza	30 False Negative (Falsos Negativos)	150 True Negative (Verdaderos Negativos)
		Tiene dolor de cabeza	No tiene dolor de cabeza
		Valores actuales	

INDICADORES CLAVE EN LA MATRIZ DE CONFUSIÓN (ESPECIFICITY)

True Negative Rate

$$\textit{Especificity} = \frac{TN}{TN + FP}$$

La Especificidad indica la capacidad del modelo para discriminar un caso negativo de uno positivo.

Representa la fracción de verdaderos negativos.

$$\textit{Recall} = \frac{150}{150 + 20} = 0.88 = 88\%$$


Esto significa que de todos los casos negativos reales, solo el 88% ser predijeron correctamente.

Valores de la predicción	Tiene dolor de cabeza	100 True Positive (Verdaderos Positivos)	20 False Positive (Falsos Positivos)
	No tiene dolor de cabeza	30 False Negative (Falsos Negativos)	150 True Negative (Verdaderos Negativos)
		Tiene dolor de cabeza	No tiene dolor de cabeza
		Valores actuales	

RESUMEN

- **Alta Precisión y Alto Recall:** El modelo de aprendizaje de máquina escogido maneja perfectamente esa clase.
- **Alta Precisión y Bajo Recall:** El modelo de aprendizaje de máquina escogido no detecta la clase muy bien, pero cuando lo hace es altamente confiable.
- **Baja Precisión y Alto Recall:** El modelo de aprendizaje de máquina escogido detecta bien la clase, pero también incluye muestras de la otra clase.
- **Baja Precisión y Bajo Recall:** El modelo de aprendizaje de máquina escogido no logra clasificar la clase correctamente.

EJEMPLO IRIS DATASET 80:20



DATOS DE CALIDAD

Relevancia

Los datos deben de ser reelevantes para el problema que vas a resolver.

Consistencia

Los atributos similares siempre deben corresponder a la etiqueta para garantizar la uniformidad en el conjunto de datos.

Uniformes

Procurar tener uniformidad en las características del conjunto de datos. Tratar de usar la misma fuente con los mismos atributos.

Consistencia

Los datos de entrenamiento deben de ser lo suficientemente grandes como para representar las caractर्सísticas suficientes que necesita para entrenar el modelo de la mejor manera.

www.uao.edu.co

GRACIAS.

